

การจำแนกความผิดปกติของเล็บ ด้วยโครงข่ายประสาทเทียมแบบคอนโวลูชัน

Classifying Nail Abnormalities by Convolutional Neural Network

ณัฐธิดา ลาภธนชัย¹, อาทิตยา ชมทอง¹, สัจจาภรณ์ ไวจรรยา^{2*}, ณัฐโชติ พรหมฤทธิ์²

¹สาขาวิชาวิทยาการข้อมูล คณะวิทยาศาสตร์ มหาวิทยาลัยศิลปากร

²ศูนย์เชี่ยวชาญปัญญาประดิษฐ์และภาษาธรรมชาติ ภาควิชาคอมพิวเตอร์ คณะวิทยาศาสตร์ มหาวิทยาลัยศิลปากร

Emails: Lapthanachai_n@silpakorn.edu, Chomthong_a@silpakorn.edu, Waijanya_s@silpakorn.edu*,

Promrit_n@silpakorn.edu

บทคัดย่อ

เล็บเป็นอวัยวะหนึ่งของร่างกาย ซึ่งลักษณะของเล็บสามารถบ่งบอกถึงสุขภาพดีหรือโรคร้ายที่เกิดต่อร่างกายได้ เพื่อสร้างโมเดลที่สามารถนำไปประยุกต์เป็นเครื่องมือจำแนกความผิดปกติของเล็บได้ด้วยตนเอง บทความนี้เสนอการศึกษาและวิเคราะห์การจำแนกความผิดปกติของเล็บ 7 ลักษณะ ได้แก่ 1) Beau's Lines on Nails 2) Black line on Nails 3) Nail Clubbing 4) Muehrcke's nails 5) Onycholysis 6) Terry's nail และ 7) White Spots on the Nails โดยรวบรวมข้อมูลจาก Google image จำนวน 700 ภาพ แบ่งเป็น Train set, Validation set และ Test set คิดเป็นอัตราส่วน 64:16:20 และเปรียบเทียบโมเดลโครงข่ายประสาทเทียม กับโมเดลโครงข่ายประสาทเทียมแบบคอนโวลูชัน พบว่า โมเดลแบบโครงข่ายประสาทเทียมแบบคอนโวลูชัน ได้ค่าความถูกต้องอยู่ที่ 80.00% ซึ่งมีประสิทธิภาพจำแนกความผิดปกติของเล็บได้มากกว่าโมเดลแบบโครงข่ายประสาทเทียมที่ได้ค่าความถูกต้องเพียง 43.57%

คำสำคัญ – เล็บผิดปกติ, การจำแนกภาพ, โครงข่ายประสาทเทียม, โครงข่ายประสาทเทียมแบบคอนโวลูชัน

ABSTRACT

Nails are one organ which can indicate the status of health condition through their own appearances. To create a model which can be applied as a tool for self-classifying nail abnormalities, this article presents the

study and analysis on 7 abnormalities of nails: 1) Beau's lines 2) Black line 3) Clubbing 4) Muehrcke's nails 5) Onycholysis 6) Terry's nail and 7) White spots. The data are 700 images compiled from Google. They are separated into Train set, Validation set, Test set, and arranged into 64:16:20 ratio respectively. The results after the comparison between Artificial Neural Networks (ANN) and Convolutional Neural Network (CNN) points out that CNN achieves 80.00% accuracy which has more efficiency in classifying nail abnormalities than ANN which only has 43.57% accuracy.

Keywords -- Abnormal Nails, Image Classification, Neural Network, Convolutional Neural Network

1. บทนำ

เล็บเกิดจากโปรตีนชนิดหนึ่ง เรียกว่า เคราติน อัดแน่นเป็นแผ่นแข็งติดชั้นหนังกำพืด เล็บถือว่าเป็นเซลล์ชั้นหนังกำพืดที่ตายแล้ว หรือเรียกได้ว่าอวัยวะหนึ่งของร่างกาย ปกคลุมอยู่บริเวณปลายนิ้วมือและนิ้วเท้า มีหน้าที่สำคัญเพื่อป้องกันปลายประสาทและเส้นเลือดที่ปลายนิ้วที่ช่วยในการควบคุมการทำงานของนิ้ว [1] นอกจากนี้ลักษณะของเล็บสามารถบ่งบอกถึงสุขภาพดีหรือโรคร้ายที่เกิดต่อร่างกายได้ด้วยเช่นกัน

บุคคลที่มีสุขภาพดี จะมีลักษณะผิวเล็บเรียบเป็นเงา เนื้อใต้

*Corresponding Author

เล็บเป็นสีชมพูอ่อน เนื้อเล็บมีความแข็งแรงและสามารถยืดหยุ่นได้ แต่บุคคลที่มีลักษณะเล็บผิดปกติจากที่กล่าวมา ลักษณะความผิดปกติอาจเป็นสัญญาณเตือนถึงอาการผิดปกติของร่างกายหรือโรคร้ายที่จะเกิดขึ้นได้ [2] เช่น เล็บมีลักษณะเป็นร่องลึกตามแนวขวาง เกิดจากภาวะขาดสารอาหาร ขาดธาตุสังกะสี เล็บมีเส้นสีดำที่ใต้ผิวเล็บ บ่งบอกถึงการเกิดโรคมะเร็งผิวหนังที่อันตราย เล็บโค้งไปรอบ ๆ เกี่ยวข้องกับโรคหัวใจ โรคปอด โรคตับ หรือโรคเอดส์ เล็บหลุดออกจากฐาน บ่งบอกถึงโรคต่อมไทรอยด์ หรือโรคสะเก็ดเงิน เล็บมีเส้นสีขาวในแนวขวาง พบในผู้ป่วยโรคไต ไตอักเสบ โรคตับ หรือผู้ที่ได้รับสารหนู เล็บเป็นสีขาวแต่มีปลายเป็นสีชมพู สามารถเกิดจากโรคหัวใจล้มเหลว โรคเบาหวาน หรือโรคตับ เล็บมีจุดสีขาว เล็บลักษณะนี้มีหลายสาเหตุ เช่น อาการแพ้ การติดเชื้อรา อาการบาดเจ็บที่เล็บ การขาดแร่ธาตุ เป็นต้น

บทความนี้เสนอการศึกษา และวิเคราะห์การจำแนกความผิดปกติของเล็บ มีวัตถุประสงค์

1) เพื่อศึกษาลักษณะความผิดปกติของเล็บต่อการเกิดอาการผิดปกติหรือโรคร้ายที่เกิดขึ้นแก่ร่างกาย

2) เพื่อเปรียบเทียบโมเดลโครงข่ายประสาท (Artificial Neural Networks: ANN) กับโมเดลโครงข่ายประสาทเทียมแบบคอนโวลูชัน (Convolutional Neural Networks: CNN)

3) เพื่อสร้างโมเดลที่สามารถนำไปประยุกต์เป็นเครื่องมือจำแนกความผิดปกติของเล็บได้ด้วยตนเอง

บทความนี้สามารถนำไปใช้เป็นแนวทางและวิธีการเบื้องต้นในการดูแลหรือตรวจสอบสุขภาพตัวเอง เพื่อทราบถึงอาการผิดปกติที่อาจจะเกิดขึ้นของร่างกายและการตัดสินใจเข้าพบแพทย์ตรวจสุขภาพร่างกายต่อไป

2. ทฤษฎีและงานวิจัยที่เกี่ยวข้อง

2.1 ลักษณะความผิดปกติของเล็บ

จากการศึกษาลักษณะความผิดปกติของเล็บ [2] พบว่าความผิดปกติของเล็บมีลักษณะที่หลากหลาย และในแต่ละลักษณะสามารถบ่งบอกถึงสาเหตุการเกิดความผิดปกติ และอาการหรือโรคที่อาจจะเกิดขึ้นกับร่างกายได้ เพื่อแสดงให้เห็นถึงภาพลักษณะความผิดปกติของเล็บที่ชัดเจนยิ่งขึ้น แสดงในตารางที่ 1

ตารางที่ 1 ลักษณะ สาเหตุ และอาการหรือโรคจากความผิดปกติของเล็บ

เล็บผิดปกติ	ลักษณะ	สาเหตุ	อาการ/โรค
 Beau's Lines	มีร่องลึกตามแนวขวาง	การเจริญเติบโตของเล็บถูกขัดขวาง	ขาดสารอาหารสังกะสี โรคปอดบวม
 Black line	มีเส้นสีดำที่ใต้ผิวเล็บ	หลุดเลือดใต้เล็บได้รับความเสียหาย หรือผลจากการใช้ยาบางชนิด	โรคมะเร็งผิวหนังที่อันตราย
 Clubbing	มีความโค้งลงไปรอบ ๆ เล็บ หนา กลม	ผลจากออกซิเจนในเลือดต่ำ	โรคหัวใจ โรคปอด โรคตับ หรือโรคเอดส์
 Muehrcke's nails	มีแถบขาวในแนวขวางบนเล็บ	ปรากฏในบุคคลที่มีภาวะ Hypoalbuminemia หรือภาวะ Albumin ในเลือดต่ำ	โรคไต ไตอักเสบ โรคตับ หรือผู้ที่ร่างกายได้รับสารหนู
 Onycholysis	ปลายหลุดออกจากฐานเล็บและเปลี่ยนเป็นสีขาว	การบาดเจ็บที่เล็บ หรือ แพ้ผลิตภัณฑ์ที่ใช้กับเล็บ	อาการของโรคเชื้อรา โรคต่อมไทรอยด์ หรือโรคสะเก็ดเงิน
 Terry's nail	เล็บเป็นสีขาวแต่มีสีชมพูแคบ ๆ ที่ปลายเล็บ	มาจากความชรา	โรคตับ ภาวะหัวใจล้มเหลว ไตวาย หรือโรคเบาหวาน
 White spots	มีจุดหรือแถบสีขาวบนเล็บ	อาการแพ้ การติดเชื้อรา อาการบาดเจ็บที่เล็บ หรือ การขาดแร่ธาตุ	เป็นปัญหาที่เกิดขึ้นโดยทั่วไปและไม่เป็นอันตราย

2.2 Image Classification ด้วย Convolution Neural Network (CNN) เอมารวมกัน และยกตัวอย่างงานที่จำแนกภาพเกี่ยวกับด้านสุขภาพ

Image Classification [3] เป็นการจำแนกข้อมูลที่อยู่ในรูปแบบรูปภาพ เพื่อแยกประเภทรูปภาพหรือสิ่งที่ปรากฏบนรูปภาพที่เป็นชนิดเดียวกันหรือแตกต่างกัน โดยจำแนกตามกลุ่มหรือหมวดหมู่ที่สนใจ วิธีการจำแนกประเภทของรูปภาพโดยทั่วไปมีหลายวิธี ซึ่งในการสร้างโมเดลจำแนกภาพด้วยวิธีการทาง Machine Learning สามารถทำได้ทั้งแบบ Supervised Learning และ Unsupervised Learning โดยในบทความวิจัยนี้จะพัฒนา Model แบบ Supervised Learning ด้วยเทคนิค Convolution Neural Network หรือ CNN [3] ที่เป็น Deep Learning ชนิดหนึ่ง โดย Neural Network ชนิดนี้ จะใช้ Convolution เพื่อดึงลักษณะที่เป็นประโยชน์สำหรับการทำโมเดลมาใช้งาน การทำงานในลักษณะนี้จะช่วยให้โมเดลสามารถเรียนรู้ได้ดีขึ้น

งานวิจัยที่จำแนกภาพด้วย CNN เช่น นพรุจ พัฒนสาร และ ณัฐวุฒิ ศรีวิบูลย์ [4] ได้ศึกษาการประมวลผลภาพสำหรับการจำแนกคุณภาพมะม่วงพันธุ์โชคอนันต์ โดยการจำลองการมองเห็นของมนุษย์ด้วยวิธีการเรียนรู้เชิงลึก โดยเก็บข้อมูลภาพมะม่วงโชคอนันต์ เพื่อการจำแนกคุณภาพ 4 ระดับได้แก่ คุณภาพระดับเกรด A, คุณภาพระดับเกรด B, คุณภาพระดับเกรด C และ คุณภาพระดับเกรด D คือมะม่วงเน่า พบว่า การใช้วิธีโครงข่ายประสาทเทียมคอนโวลูชัน ในการประมวลผลภาพ มีค่าความแม่นยำสูงสุดคือ 99.79% และมีอัตราความสำเร็จ 100% เมื่อนำมาใช้จำแนก คุณภาพมะม่วงโชคอนันต์

2.3 Batch Normalization

Batch Normalization [3] เป็นการ Scaling Data หรือ Normalization ให้อยู่ในช่วงที่กำหนด ซึ่งจะใช้ในระหว่างการฝึกฝนโมเดล ในการคำนวณจะคำนวณจากขนาดของ Batch หรือกลุ่มของข้อมูลที่ถูกกำหนดจำนวนไว้ ซึ่งการทำ Normalization สามารถทำได้หลายวิธี เช่น Min-Max Normalization หรือ Standardization เป็นต้น

2.4 Drop Out

Drop Out [3] เป็นเทคนิคของการทำ Regularity ซึ่งเป็นการสุ่มปิด Node ของ Layer นั้นชั่วคราวในระหว่างการฝึกฝนโมเดล และสามารถช่วยลดการเกิดปัญหา Overfitting ได้

2.5 Data Augmentation

Data Augmentation [3] เป็นการเพิ่มจำนวนข้อมูลให้กับชุดข้อมูลฝึกฝน (train set) โดยนำรูปภาพมาปรับเปลี่ยน เพื่อให้โมเดลเรียนรู้ได้มากขึ้น สามารถทำได้ในหลากหลายวิธี เช่น ย่อขยาย ตัดรูป หมุน หรือเลื่อนตำแหน่งภาพ เป็นต้น ทั้งนี้ การทำ Data Augmentation สามารถช่วยลดปัญหา Overfitting ของโมเดล นั่นคือ โมเดลเรียนรู้จากชุดข้อมูลฝึกฝนได้ดี แต่ไม่สามารถนำไปใช้กับชุดข้อมูลทดสอบได้ หรือข้อมูลที่เป็น unseen data ได้ คือ ผลจากการวัดประสิทธิภาพโมเดลได้ค่าความถูกต้องของชุดข้อมูลทดสอบต่ำกว่าค่าความถูกต้องของชุดข้อมูลฝึกฝน

งานวิจัยที่นำเทคนิค Data Augmentation มาใช้งาน

1) การปรับปรุงประสิทธิภาพในการจำแนกภาพด้วยโครงข่ายประสาทแบบคอนโวลูชันโดยใช้เทคนิคการเพิ่มภาพ งานวิจัยนี้มีวัตถุประสงค์เพื่อปรับปรุงประสิทธิภาพในการจำแนกภาพด้วยโครงข่ายประสาทแบบคอนโวลูชันโดยใช้เทคนิค Data Augmentation ซึ่งการทำเช่นนี้ช่วยให้ประสิทธิภาพในการจำแนกภาพแม่นยำสูงขึ้นจาก 84.79% เป็น 87.57% [5]

2) การปรับปรุงประสิทธิภาพการจำแนกภาพเอกซเรย์ทรวงอกโดยโครงข่ายประสาทเทียมแบบสังวัตนาการโดยใช้เทคนิคการเพิ่มภาพสำหรับวินิจฉัยโรคโควิด-19 งานวิจัยนี้มีวัตถุประสงค์เพื่อปรับปรุงประสิทธิภาพการจำแนกภาพเอกซเรย์ทรวงอกสำหรับวินิจฉัยโรคโควิด-19 โดยใช้โครงข่ายประสาทแบบคอนโวลูชัน ซึ่งพบว่าการหมุนภาพทำให้ประสิทธิภาพในการจำแนกเท่ากับ 99.67% สำหรับการจำแนกภาพเอกซเรย์ทรวงอกสำหรับวินิจฉัยโรคโควิด-19 [6]

3) แบบจำลองการคัดแยกผลไม้แบบหนึ่งชนิดด้วยการเรียนรู้ของเครื่องเพื่อตรวจจับรูปแบบเปลือก จากงานวิจัยนี้ พบว่า วิธี IANET พร้อมกับการใช้ Data Augmentation ให้ค่าความถูกต้อง 98.60% ซึ่งเมื่อ เทียบกับวิธี IANET และไม่ใช่ Data Augmentation จะได้ค่าความถูกต้องเพียง 98.06% [7]

2.6 High Boost Filtering

การใช้ Filter สำหรับการทำ Image Processing จะคล้ายกับการทำ Point Operation เป็นการปรับค่าที่อยู่ในแต่ละ Pixel โดยไม่สนใจ Pixel ที่อยู่รอบ ๆ เพื่อให้รูปภาพนั้นมีความสว่างหรือคมชัดมากขึ้น เป็นต้น แต่การใช้ Filter นั้น จะปรับค่าของแต่ละ Pixel โดยสนใจ Pixel อื่นที่อยู่รอบ ๆ Pixel นั้นด้วย ซึ่งสามารถกำหนดจำนวนของ Pixel ที่สนใจ จะนำมาคำนวณ

ด้วยได้ จำนวน Pixel ถูกกำหนดในรูปแบบของเมทริกซ์จัตุรัส เช่น 3x3 หรือ 5x5 เป็นต้น

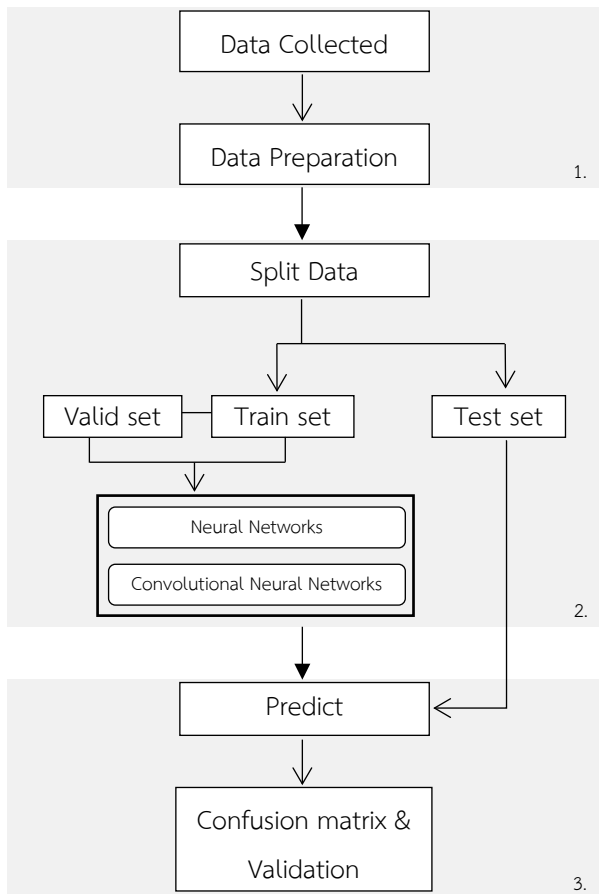
High Boost Filtering [8] เป็นหนึ่งในหมวดหมู่ของ Filter ที่ใช้ในการปรับความคมชัดของรูปภาพ โดย High Boost Filter มีรูปแบบมาตรฐาน ดังภาพที่ 1

$$\text{oooooo} = \begin{bmatrix} -1 & -1 & -1 \\ -1 & 9 & -1 \\ -1 & -1 & -1 \end{bmatrix}$$

ภาพที่ 1 Image Filter

3. กระบวนการออกแบบและพัฒนาโมเดล

3.1 ภาพรวมของกระบวนการ (Process Overview)



ภาพที่ 2 ภาพรวมของกระบวนการดำเนินงาน

งานวิจัยนี้ใช้ภาษาโปรแกรม Python 3.8 ในกระบวนการทำงาน ดังภาพที่ 2 แบ่งออกเป็น 3 ส่วน ได้แก่

ส่วนที่ 1 การเก็บรวบรวมข้อมูลและเตรียมข้อมูลให้พร้อมใช้งาน

ส่วนที่ 2 การแบ่งข้อมูลและสร้างโมเดล


ส่วนที่ 3 การทำนาย ประเมินและวัดประสิทธิภาพโมเดล แสดงรายละเอียด ในหัวข้อต่อไป

3.2 การรวบรวมข้อมูลและเตรียมข้อมูลให้พร้อมใช้งาน

3.2.1 ขั้นแรก Data Collected เก็บรวบรวมภาพความผิดปกติของเล็บโดยใช้ Image Search จาก Google ทั้งหมด 7 ลักษณะ ได้แก่ 1) Beau's Lines on Nails 2) Black line on Nails 3) Nail Clubbing 4) Muehrcke's nails 5) Onycholysis 6) Terry's nail และ 7) White Spots on the Nails เก็บภาพแต่ละลักษณะจำนวน 100 ภาพ รูปแบบไฟล์ .jpg

3.2.2 ขั้นตอน Data Preparation ตัดส่วนขอบของภาพเพื่อให้เห็นความผิดปกติของเล็บได้ชัดเจนขึ้น และปรับขนาดของภาพให้มีขนาดเท่ากัน กำหนดความกว้าง เท่ากับ 100 Pixels และความยาว เท่ากับ 100 Pixels เพื่อให้ขนาดไฟล์ภาพไม่ใหญ่จนเกินไปและใช้เวลาในการ Train น้อยลง หลังจากนั้นนำภาพมาทำ Image Filtering ใช้ขนาดของเมทริกซ์เป็น 3x3 และใช้ Filter ที่เป็นมาตรฐานของ High Boost Filtering ดังภาพที่ 1

เนื่องจากการใช้ Filter ในรูปแบบนี้จะทำให้รูปมีความคมชัดและเห็นรายละเอียดของเล็บมากขึ้น ซึ่งสามารถเปรียบเทียบได้ดังภาพที่ 3



ภาพที่ 3 ตัวอย่างภาพเปรียบเทียบการใช้ Image Filtering

3.3 การแบ่งข้อมูลและการสร้างโมเดล

3.3.1 การแบ่งข้อมูล ใช้ sklearn แบ่งข้อมูลออกเป็น 3 ชุด ได้แก่ ชุดข้อมูลสำหรับฝึกฝนโมเดล (Train data set) ชุดข้อมูลสำหรับตรวจสอบโมเดล (Valid data set) และชุดข้อมูลสำหรับทดสอบโมเดล (Test data set) ซึ่งผู้วิจัยจะแบ่งชุดข้อมูลฝึกฝนกับชุดข้อมูลทดสอบก่อน ใช้อัตราส่วน 80:20 โดยแบ่งภาพในแต่ละลักษณะ หลังจากนั้นจึงแบ่งชุดข้อมูลตรวจสอบจากชุดข้อมูลฝึกฝน ใช้อัตราส่วน 80:20 เช่นกัน จะได้ชุดข้อมูลทั้งหมด 3 ชุด ดังนี้ ชุดข้อมูลสำหรับฝึกฝน 448 ภาพ ชุดข้อมูลสำหรับตรวจสอบ 112 ภาพ และชุดข้อมูลสำหรับทดสอบ 140 ภาพ คิดเป็นอัตราส่วนทั้งหมด 64:16:20

3.3.2 การสร้างโมเดล แบ่งเป็น 2 โมเดล คือ โมเดลแบบโครงข่ายประสาทเทียม (ANN) และโมเดลแบบโครงข่ายประสาทเทียมแบบคอนโวลูชัน (CNN) โดยนิยามโมเดล ดังนี้

1) โมเดลโครงข่ายประสาทเทียม (Artificial Neural Network) รายละเอียดพารามิเตอร์ของโมเดล ดังภาพที่ 4 และสร้างโมเดลซึ่งประกอบด้วย layer ต่าง ๆ ดังภาพที่ 5 มีรายละเอียดของแต่ละ layer ดังต่อไปนี้


Input layer กำหนด input shape = (90, 90, 3)

Hidden layer ใช้ ReLu activation function

Output layer ใช้ Softmax activation function และกำหนด Neuron เท่ากับ 7 (เท่ากับจำนวนความผิดปกติของเล็บ) กำหนด Optimizer แบบ Adam (Adaptive Moment Estimation) จำนวน Epoch 1000 รอบ และขนาดของ Batch จำนวน 32 ภาพ เพื่อใช้ทำ Batch Normalization

Model: "sequential"		
Layer (type)	Output Shape	Param #
conv2d (Conv2D)	(None, 90, 90, 32)	896
activation (Activation)	(None, 90, 90, 32)	0
conv2d_1 (Conv2D)	(None, 90, 90, 32)	9248
activation_1 (Activation)	(None, 90, 90, 32)	0
max_pooling2d (MaxPooling2D)	(None, 18, 18, 32)	0
conv2d_2 (Conv2D)	(None, 18, 18, 64)	18496
activation_2 (Activation)	(None, 18, 18, 64)	0
conv2d_3 (Conv2D)	(None, 18, 18, 64)	36928
activation_3 (Activation)	(None, 18, 18, 64)	0
max_pooling2d_1 (MaxPooling2D)	(None, 3, 3, 64)	0
flatten (Flatten)	(None, 576)	0
dense (Dense)	(None, 256)	147712
activation_4 (Activation)	(None, 256)	0
dense_1 (Dense)	(None, 7)	1799
Total params: 215,079		
Trainable params: 215,079		
Non-trainable params: 0		

ภาพที่ 4 รายละเอียดของโมเดลโครงข่ายประสาทเทียม



ภาพที่ 5 โครงสร้างของโมเดลโครงข่ายประสาทเทียม

2) โมเดลโครงข่ายประสาทเทียมแบบคอนโวลูชัน (Convolutional Neural Network) นำชุดข้อมูลสำหรับฝึกฝนมาทำ Image Augmentation โดยกำหนดรายละเอียดต่าง ๆ ดังนี้

1. การหมุนภาพแบบสุ่ม กำหนดในช่วงไม่เกิน 0.05 องศา
2. การขยายภาพแบบสุ่ม กำหนดในช่วงไม่เกิน 30%
3. การเลื่อนภาพแนวขวางแบบสุ่ม กำหนดในช่วงไม่เกิน 10%
4. การเลื่อนภาพในแนวยาวแบบสุ่ม กำหนดในช่วงไม่เกิน 10%
5. การบิดภาพแบบสุ่ม กำหนดในช่วงไม่เกิน 0.05%

หลังจากกำหนดรายละเอียด Image Augmentation เสร็จแล้ว ขั้นตอนต่อไปจะสร้างโมเดล โดยรายละเอียดพารามิเตอร์ของโมเดล ดังภาพที่ 6 และสร้างโมเดลซึ่งประกอบด้วย layer ต่าง ๆ ดังภาพที่ 7 มีรายละเอียดของแต่ละ layer ดังต่อไปนี้

Input layer กำหนด input shape = (90, 90, 3)


Hidden layer ใช้ ReLu activation function กำหนดค่า Dropout เท่ากับ 0.1 และทำ Batch Normalization

Output layer ใช้ Softmax activation function และกำหนด Neuron เท่ากับ 7 (เท่ากับจำนวนความผิดปกติของเล็บ)

กำหนด Optimizer แบบ Adam (Adaptive Moment Estimation) Learning Rate เท่ากับ 0.001 จำนวน Epoch 1000 รอบ และขนาดของ Batch จำนวน 10 ภาพ เพื่อใช้ทำ Batch Normalization

Model: "sequential_1"		
Layer (type)	Output Shape	Param #
conv2d_4 (Conv2D)	(None, 90, 90, 32)	896
batch_normalization_1 (Batch Normalization)	(None, 90, 90, 32)	128
activation_5 (Activation)	(None, 90, 90, 32)	0
dropout_1 (Dropout)	(None, 90, 90, 32)	0
conv2d_5 (Conv2D)	(None, 90, 90, 32)	9248
batch_normalization_2 (Batch Normalization)	(None, 90, 90, 32)	128
activation_6 (Activation)	(None, 90, 90, 32)	0
max_pooling2d_2 (MaxPooling2D)	(None, 18, 18, 32)	0
dropout_2 (Dropout)	(None, 18, 18, 32)	0
conv2d_6 (Conv2D)	(None, 18, 18, 64)	18496
batch_normalization_3 (Batch Normalization)	(None, 18, 18, 64)	256
activation_7 (Activation)	(None, 18, 18, 64)	0
dropout_3 (Dropout)	(None, 18, 18, 64)	0
conv2d_7 (Conv2D)	(None, 18, 18, 64)	36928
batch_normalization_4 (Batch Normalization)	(None, 18, 18, 64)	256
activation_8 (Activation)	(None, 18, 18, 64)	0
max_pooling2d_3 (MaxPooling2D)	(None, 3, 3, 64)	0
dropout_4 (Dropout)	(None, 3, 3, 64)	0
flatten_1 (Flatten)	(None, 576)	0
dense_2 (Dense)	(None, 256)	147712
batch_normalization_5 (Batch Normalization)	(None, 256)	1024
activation_9 (Activation)	(None, 256)	0
dropout_5 (Dropout)	(None, 256)	0
dense_3 (Dense)	(None, 7)	1799
Total params: 216,871		
Trainable params: 215,975		
Non-trainable params: 896		

ภาพที่ 6 รายละเอียดของโมเดลโครงข่ายประสาทเทียมแบบคอนโวลูชัน



ภาพที่ 7 โครงสร้างของโมเดลโครงข่ายประสาทเทียมแบบคอนโวลูชัน

3.4 ทำนายและการประเมินโมเดล

หลังจากที่สร้างโมเดลเสร็จแล้ว นำชุดข้อมูลสำหรับทดสอบมาทดสอบความถูกต้องและความแม่นยำของการทำนายของโมเดลโดยคำนวณค่า AUC ของภาพแต่ละคลาส สร้าง ROC Curve และ Confusion matrix โดยใช้การเทียบค่า True

Positive (TP), False Positive (FP), False Negative (FN) และ True Negative (TN) ดังตารางที่ 2 จะได้ค่า Accuracy ดังสมการที่ 1, Precision ดังสมการที่ 2, Recall ดังสมการที่ 3 และ F1-score ดังสมการที่ 4 จากนั้นสร้างกราฟ Accuracy และกราฟ Loss ของชุดข้อมูลสำหรับฝึกฝนโมเดลกับชุดข้อมูลสำหรับตรวจสอบโมเดล เพื่ออธิบาย วิเคราะห์ผล และประเมินโมเดล

ตารางที่ 2 ตารางเทียบค่าคำนวณความถูกต้องและความแม่นยำ

		Actual	
		Positive	Negative
Predict	Positive	TP	FP
	Negative	FN	TN

$$\text{Accuracy} = \frac{TP + TN}{TP + FP + FN + TN} \quad (1)$$

$$\text{Precision} = \frac{TP}{TP + FP} \quad (2)$$

$$\text{Recall} = \frac{TP}{TP + FN} \quad (3)$$

$$\text{F1 - Score} = \frac{2 \times \text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}} \quad (4)$$


4. ผลการดำเนินการวิจัย

การจำแนกความผิดปกติของเล็บใช้ชุดข้อมูลสำหรับฝึกฝนโมเดล 448 ภาพ ชุดข้อมูลสำหรับตรวจสอบโมเดล 112 ภาพ และชุดข้อมูลสำหรับทดสอบโมเดล 140 ภาพ ได้ผลลัพธ์การจำแนกความผิดปกติของเล็บทั้ง 2 โมเดล ดังต่อไปนี้

4.1 ผลการประเมินประสิทธิภาพการจำแนกของโมเดล


โครงข่ายประสาทเทียม

กำหนดค่า epochs 1000 รอบ และ batch size เท่ากับ 32 ในการทดสอบโมเดล แสดงผลลัพธ์ที่ได้จากการสังเกตค่า Accuracy ในกราฟภาพที่ 8 และค่า Loss ในกราฟภาพที่ 9



ภาพที่ 8 กราฟ Training accuracy กับ Validation accuracy โมเดล ANN

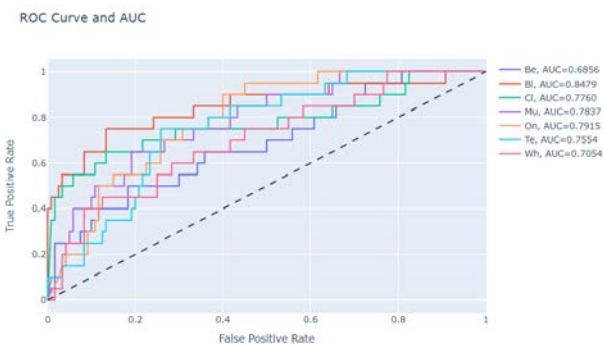
จากการสังเกตกราฟค่า Training accuracy กับ Validation accuracy พบว่า ค่า Accuracy สำหรับชุดข้อมูลฝึกฝนโมเดลเพิ่มขึ้นอย่างต่อเนื่องในช่วงประมาณรอบที่ 1 ถึงรอบที่ 20 จากนั้นคงที่ ที่ค่า Accuracy เท่ากับ 1.0 และสำหรับชุดข้อมูลตรวจสอบโมเดลค่า Accuracy เพิ่มขึ้นอย่างต่อเนื่องในช่วงประมาณรอบที่ 1 ถึงรอบที่ 20 จากนั้นค่าคงที่ ที่ค่า Accuracy ประมาณ 0.5



ภาพที่ 9 กราฟ Training loss กับ Validation loss โมเดล ANN


จากการสังเกตกราฟค่า Training loss กับ Validation loss พบว่า ค่า Loss สำหรับชุดข้อมูลฝึกฝนโมเดลลดลงอย่างต่อเนื่องในช่วงประมาณรอบที่ 1 ถึงรอบที่ 20 จากนั้นค่าคงที่ ที่ค่า Loss เท่ากับ 0 และสำหรับชุดข้อมูลตรวจสอบโมเดลมีแนวโน้มค่า Loss เพิ่มขึ้นอย่างต่อเนื่อง

จากกราฟแสดงค่า Accuracy และ ค่า Loss ของชุดข้อมูลสำหรับฝึกฝนโมเดลและชุดข้อมูลสำหรับตรวจสอบโมเดลสามารถประเมินโมเดล ANN พบว่า โมเดลเกิดปัญหา Overfitting หรือ โมเดลมีการเรียนรู้ที่มากเกินไปจากชุดข้อมูลสำหรับฝึกฝนโมเดล นำชุดข้อมูลทดสอบโมเดลไปทำนายผล ได้ค่าทำนายเปรียบเทียบผลเฉลี่ย แสดงค่า AUC และ ROC Curve ในภาพที่ 10 และแสดง Confusion Matrix ในภาพที่ 11



ภาพที่ 10 กราฟ ROC Curve และค่า AUC แต่ละคลาสของโมเดล ANN

จากภาพที่ 10 พบว่าค่า AUC ของ Class Bl หรือ Black line มีค่าสูงที่สุดเท่ากับ 0.8479 และค่า AUC ของ Class Be หรือ Beau's line มีค่าต่ำที่สุดเท่ากับ 0.6856



ภาพที่ 11 ค่า Confusion Matrix โมเดล ANN

จากภาพที่ 11 พบว่า Class Te หรือ Terry's nail สามารถจำแนกได้ถูกต้องมากที่สุด ซึ่งสามารถจำแนกได้ถูกต้อง 16 ภาพจากทั้งหมด 20 ภาพ และ Class Wh หรือ White spots จำแนกได้ถูกต้องน้อยที่สุด ซึ่งสามารถจำแนกได้ถูกต้องเพียง 10 ภาพจากทั้งหมด 20 ภาพ และค่า Confusion Matrix ข้างต้น เมื่อนำมาเทียบค่า คำนวณความถูกต้องและความแม่นยำ จะได้ค่า Accuracy, Precision, Recall และ F1-score ดังตารางที่ 3

ตารางที่ 3 Precision Recall และ F1 Score โมเดล NN


	Precision	Recall	F1-score	Support	Accuracy
Be	0.3200	0.4000	0.3556	20	0.4357
Bl	0.6471	0.5500	0.5946	20	
Cl	0.5882	0.5000	0.5405	20	
Mu	0.5000	0.4000	0.4444	20	
On	0.4167	0.5000	0.4545	20	
Te	0.2917	0.3500	0.3182	20	
Wh	0.4118	0.3500	0.3784	20	

Be = Beau's lines on Nails, Bl = Black line on Nails, Cl = Nail Clubbing, Mu = Muehrcke's Nails, On = Onycholysis, Te = Terry's Nail, Wh = White Spots on the Nails

จากตารางที่ 3 ได้ผลลัพธ์การจำแนกความผิดปกติของเล็บ ด้วยโมเดล ANN มีค่าความถูกต้องอยู่ที่ 43.57%


4.2 ผลการประเมินประสิทธิภาพการจำแนกของโมเดล โครงข่ายประสาทเทียมแบบคอนโวลูชัน

กำหนดค่า epochs 1000 รอบ และ batch size เท่ากับ 10 ในการทดสอบโมเดล แสดงผลลัพธ์ที่ได้จากการสังเกตค่า Accuracy ในกราฟภาพที่ 12 และค่า Loss ในกราฟภาพที่ 13



ภาพที่ 12 กราฟ Training accuracy กับ Validation accuracy โมเดล CNN

จากการสังเกตกราฟค่า Training accuracy กับ Validation accuracy พบว่า ค่า Accuracy สำหรับชุดข้อมูลฝึกฝนโมเดล และชุดข้อมูลตรวจสอบโมเดลมีแนวโน้มเพิ่มขึ้นเรื่อย ๆ ในช่วงประมาณรอบที่ 1 ถึงรอบที่ 200 หลังจากนั้นค่า Accuracy เริ่มคงที่ใกล้เคียงค่า 1.0




ภาพที่ 13 กราฟ Training loss กับ Validation loss โมเดล CNN

จากการสังเกตกราฟค่า Training loss กับ Validation loss พบว่า ค่า Loss สำหรับชุดข้อมูลฝึกฝนโมเดลและชุดข้อมูลตรวจสอบโมเดลมีแนวโน้มลดลงเรื่อย ๆ ในช่วงประมาณรอบที่ 1 ถึงรอบที่ 200 จากนั้นค่า Loss เริ่มคงที่ใกล้เคียงค่า 0

จากกราฟแสดงค่า Accuracy และ ค่า Loss ของชุดข้อมูลสำหรับฝึกฝนโมเดลและชุดข้อมูลสำหรับตรวจสอบโมเดล สามารถประเมินโมเดล CNN ได้ว่า โมเดลสามารถทำนายข้อมูลไม่ที่เคยเห็นได้อย่างมีประสิทธิภาพ นำชุดข้อมูลทดสอบโมเดลไปทำนายผล ได้ค่าทำนายเปรียบเทียบผลเฉลย แสดงค่า AUC และ


ROC Curve ในภาพที่ 14 และแสดง Confusion Matrix ในภาพที่ 15

ROC Curve and AUC



ภาพที่ 14 กราฟ ROC Curve และค่า AUC แต่ละคลาสของโมเดล CNN

จากภาพที่ 14 พบว่าค่า AUC ของ Class Te หรือ Terry's nail มีค่าสูงที่สุดเท่ากับ 0.9883 และค่า AUC ของ Class Be หรือ Beau's line มีค่าต่ำที่สุดเท่ากับ 0.9208



ภาพที่ 15 ค่า Confusion Matrix โมเดล CNN

จากภาพที่ 15 พบว่า Class Cl หรือ Nail Clubbing และ Te หรือ Terry's nail สามารถจำแนกได้ถูกต้องมากที่สุด ซึ่งสามารถจำแนกได้ถูกต้อง 19 ภาพจากทั้งหมด 20 ภาพ และ Class Bl หรือ Black line และ Mu หรือ Muehrcke's nails จำแนกได้ถูกต้องน้อยที่สุด ซึ่งสามารถจำแนกได้ถูกต้องเพียง 13 ภาพจากทั้งหมด 20 ภาพ และค่า Confusion Matrix ข้างต้น เมื่อนำมาเทียบค่า คำนวณความถูกต้องและความแม่นยำ จะได้ค่า Accuracy, Precision, Recall และ F1-score ดังตารางที่ 4

ตารางที่ 4 Precision Recall และ F1 Score โมเดล CNN

	Precision	Recall	F1-score	Support	Accuracy
Be	0.7143	0.7500	0.7371	20	0.8000
Bl	0.9286	0.6500	0.7647	20	
Cl	0.8261	0.9500	0.8837	20	
Mu	0.8667	0.6500	0.7429	20	

On	0.8889	0.8000	0.8421	20
Te	0.6786	0.9500	0.7971	20
Wh	0.8095	0.8500	0.8293	20
Be = Beau's lines on Nails, Bl = Black line on Nails, Cl = Nail Clubbing, Mu = Muehrcke's Nails, On = Onycholysis, Te = Terry's Nail, Wh = White Spots on the Nails				

จากตารางที่ 4 ได้ผลลัพธ์การจำแนกความผิดปกติของเล็บ ด้วยโมเดล CNN มีความถูกต้องอยู่ที่ 80.00%

5. สรุป และแนวทางในอนาคต

บทความนี้เสนอการศึกษาและวิเคราะห์การจำแนกความผิดปกติของเล็บ 7 ลักษณะ ได้แก่ 1) Beau's Lines on Nails 2) Black line on Nails 3) Nail Clubbing 4) Muehrcke's nails 5) Onycholysis 6) Terry's nail และ 7) White Spots on the Nails โดยรวบรวมข้อมูลจาก Google image จำนวน 700 ภาพ แบ่งเป็น Train set, Validation set และ Test set อัตราส่วน 64:16:20 และเปรียบเทียบโมเดลโครงข่ายประสาทเทียม (ANN) กับโมเดลโครงข่ายประสาทเทียมแบบคอนโวลูชัน (CNN) พบว่าโมเดลโครงข่ายประสาทเทียม (ANN) เกิดปัญหา Overfitting อธิบายได้ว่าโมเดลมีการเรียนรู้ที่มากเกินไป จากชุดข้อมูลสำหรับฝึกฝนโมเดล รวมถึงความผันผวนของชุดข้อมูลสำหรับฝึกฝน จึงทำให้โมเดลไม่สามารถจำแนกความผิดปกติของเล็บได้อย่างถูกต้อง ซึ่งได้ค่าความถูกต้องเพียง 43.57 % เมื่อเทียบกับโมเดลโครงข่ายประสาทเทียมแบบคอนโวลูชัน ที่ได้ค่าความถูกต้องถึง 80.00 % เนื่องจากโมเดลโครงข่ายประสาทเทียมแบบคอนโวลูชันมีการสกัดคุณลักษณะจากภาพเพิ่มขึ้นในแต่ละ layer และทำ Image Augmentation เพื่อเพิ่มจำนวนภาพสำหรับชุดข้อมูลฝึกฝนช่วยลดปัญหาการเกิด Overfitting ทำให้โมเดลโครงข่ายประสาทเทียมแบบคอนโวลูชันมีประสิทธิภาพในการจำแนกความผิดปกติของเล็บที่ดีกว่าโมเดลแบบโครงข่ายประสาทเทียม

ลักษณะความผิดปกติของเล็บมีลักษณะที่หลากหลายมากกว่าที่ผู้วิจัยนำมาจำแนกในบทความนี้ ดังนั้นสามารถพัฒนาโมเดลให้ครอบคลุมความผิดปกติของเล็บในลักษณะอื่น ๆ เพิ่มขึ้น เพื่อนำไปประยุกต์เป็นเครื่องมือจำแนกความผิดปกติของเล็บและสามารถตรวจสอบสุขภาพได้ด้วยตนเอง เพื่อทราบถึงอาการผิดปกติที่อาจจะเกิดขึ้น นำไปสู่การพบแพทย์และการเข้ารับการรักษา

เอกสารอ้างอิง

- [1] ชนิตา ฉันทวนิชย์. การวิจัยและพัฒนาผลิตภัณฑ์เคลือบเล็บชนิดลอกออกได้. หลักสูตรวิทยาศาสตรมหาบัณฑิต สาขาวิชาวิทยาศาสตร์เครื่องสำอาง สำนักวิชาวิทยาศาสตร์เครื่องสำอาง มหาวิทยาลัยแม่ฟ้าหลวง, 2558.
- [2] R. S. Fawcett, M. Thomas, and L. Daniel, "Nail Abnormalities: Clues to Systemic Disease," *Ameri Family Physician*, vol. 69, no. 6, pp. 1417–1424, 15 Mar. 2004
- [3] ณัฐโชติ พรหมฤทธิ์ และ สัจจาภรณ์ ไวจรรยา. Fundamental of DEEP LEARNING in Practice. พิมพ์ครั้งที่ 1. กรุงเทพฯ : สำนักพิมพ์อินโฟเพรส, 2564.
- [4] นพรุจ พัฒนสาร และ ณัฐวุฒิ ศรีวิบูลย์, "การประมวลผลภาพสำหรับการจำแนกคุณภาพมะม่วงพันธุ์โชคอนันต์ โดยการจำลองการมองเห็นของมนุษย์ด้วยวิธีการเรียนรู้เชิงลึก," *Journal of Information Science and Technology*, Vol. 10, No. 1, pp. 24-29, Jan. - Jun. 2020.
- [5] พิมพ์ ชีวาประกอบกิจ. การปรับปรุงประสิทธิภาพในการจำแนกภาพด้วยโครงข่ายประสาทแบบคอนโวลูชันโดยใช้เทคนิคการเพิ่มภาพ. คณะเทคโนโลยีสารสนเทศ มหาวิทยาลัยนานาชาติ เอเชีย-แปซิฟิก, 2562.
- [6] ณัฐวุฒิ ศรีวิบูลย์. การปรับปรุงประสิทธิภาพการจำแนกภาพเอกซเรย์ทรวงอกด้วยโครงข่ายประสาทเทียมแบบสังวัตนาการโดยใช้เทคนิคการเพิ่มภาพสำหรับวินิจฉัยโรคโควิด-19. สาขาวิทยาการสารสนเทศและดิจิทัล คณะวิทยาศาสตร์และเทคโนโลยี สุขภาพ มหาวิทยาลัยกาฬสินธุ์, 2563.
- [7] ศิริชัย โชติชาติมาลา และนุวิทย์ วิวัฒน์วัฒนา. แบบจำลองการคัดแยกผลไม้แบบหนึ่งชนิดด้วยการเรียนรู้ของเครื่องเพื่อตรวจจับรูปแบบเปลือก. สาขาวิชาวิทยาการข้อมูล, คณะวิทยาศาสตร์ มหาวิทยาลัยศรีนครินทรวิโรฒ กรุงเทพมหานคร, 2563.
- [8] M. Alirezanejad, V. Saffari, S. Amirgholipour and A. M. Sharifi, "Effect of Locations of using High Boost Filtering on the Watermark Recovery in Spatial Domain Watermarking," *Indian Journal of Science and Technology*, vol. 7, no. 4, pp. 517–524, Apr. 2014.